

Reconhecimento de Padrões:

Atividade 06 – Redes Neurais

Carlos Emmanuel Pereira Alves
Curso de Bacharelado em Ciência da Computação
Universidade Federal do Agreste de Pernambuco (UFAPE)
Garanhuns, Brasil
carlos.emmanuel.236@gmail.com

1) Utilizado a base Iris, <https://archive.ics.uci.edu/ml/datasets/Iris>. Os 25 primeiros exemplos de cada classe serão o conjunto de treino, os outros exemplos são o conjunto de teste. Faça sua própria implementação de Neurônio Artificial.

- a) Treine um neurônio para classificar a classe Iris-setosa como 1 e as demais como zero. Pare o algoritmo de treinamento com erro zero no conjunto de treino. Calcule o erro no conjunto de teste.

Erro no conjunto de teste: 0.02666666666666667

- b) Treine um neurônio para classificar a classe Iris-virgínica como 1 e as demais como zero. Pare o algoritmo de treinamento após 100 épocas. Calcule o erro no conjunto de teste.

Erro no conjunto de teste: 0.01333333333333334

- c) Inicie os pesos aleatoriamente, cada peso tem um valor randômico uniformemente distribuído entre 0 e 1. Repita o processo das letras (a) e (b) 30 vezes para três valores distintos de taxa de aprendizagem 0,1; 1,0 e 10,0. Calcule a média e o desvio padrão das taxas de erro.

LETRA A

Taxa de aprendizagem: 0.1

Erro médio: 0.01911111111111111

Desvio padrão do erro: 0.012734710028350579

LETRA A

Taxa de aprendizagem: 1.0

Erro médio: 0.018666666666666665

Desvio padrão do erro: 0.014442734941575042

LETRA A

Taxa de aprendizagem: 10.0

Erro médio: 0.003111111111111114

Desvio padrão do erro: 0.005639367795755343

LETRA B

Taxa de aprendizagem: 0.1

Erro médio: 0.032

Desvio padrão do erro: 0.010666666666666665

LETRA B

Taxa de aprendizagem: 1.0

Erro médio: 0.031999999999999994

Desvio padrão do erro: 0.013154354299509993

LETRA B

Taxa de aprendizagem: 10.0

Erro médio: 0.032888888888888884

Desvio padrão do erro: 0.011278735591510686

2) Utilizando o dataset Wine <https://archive.ics.uci.edu/ml/datasets/wine> e alguma biblioteca de redes neurais (sugestão, <https://github.com/JeffersonLPLima/ANN>, ver também o link com exemplo para a base Iris). Utilize 50% dos dados para treino e o restante para teste.

- a) Ajuste os parâmetros da rede (número de épocas de treino, número de neurônios por camada etc.) para que a acurácia seja maior que 74%. Talvez os dados precisem de pré-processamento para corrigir escalas muito discrepantes.
Acurácia: 87%

- b) Depois de a rede estar ajustada, realize 30 repetições de holdout para calcular a média e desvio padrão da acurácia.
Desvio Padrão = 0.05733641523281246
Média = 0.8921348412831624

3) Considere o conjunto de dados Spiral com apenas dois atributos descritos na figura abaixo. Foram treinadas várias redes MLP com função de ativação Sigmoide, sendo 70% dos dados utilizados para treinamento e o restante para teste. Os resultados dos experimentos estão descritos a seguir.

- a) Explique as taxas de acurácia de cada caso, comparando com outros casos.
- b) Qual configuração você escolheria? Por quê? Você proporia uma configuração distinta? Por quê?
- c) Replique os resultados destes experimentos. Calcule a média para 30 repetições em cada caso.
- d) Implemente uma variação do Caso 3 que rode por 5.000 épocas. Mostre as curvas de erro tanto para o conjunto de treino como para o conjunto de teste a cada 100 épocas de treinamento.
- e) Avalie outras três configurações da rede, buscando uma maior acurácia, variando os 5 parâmetros utilizados abaixo (número de época, taxa de aprendizagem, número de neurônios na 1a, 2a e 3a camadas escondidas).